



Model-based learning Examen du 29/11/2021 Durée : 2h - Tous documents autorisés

Nous nous intéressons au temps X d'attente (en minutes) de clients sur le standard téléphonique de leur fournisseur internet, modélisé par une loi exponentielle de densité :

$$f(x) = \begin{cases} \lambda e^{-\lambda x} & \text{si } x \geq 0 \\ 0 & \text{sinon.} \end{cases}$$

1 Clustering

Nous considérons un échantillon $\underline{X} = (X_i)_{i=1,\dots,n}$, et nous souhaitons dans un premier temps réaliser un clustering de ces données en K clusters.

1. Ecrire la vraisemblance $L(\theta, \underline{X})$ du modèle de mélange de lois exponentielles de paramètre $\theta = (\pi_k, \lambda_k)_{1 \leq k \leq K}$ pour l'échantillon $\underline{X}$, où π_k est la proportion du cluster k dans le mélange, et $1/\lambda_k$ l'espérance du temps d'attente pour le cluster k .
2. Pouvez-vous maximiser analytiquement cette vraisemblance ? Si non pourquoi ?
3. Considérons $Z_i = (Z_{ik})_{1 \leq k \leq K}$ la variable indiquant à quel cluster l'observation i appartient ($Z_{ik} = 1$ si l'observation i appartient au cluster k , 0 sinon), et $\underline{Z} = (Z_i)_{i=1,\dots,n}$. La loi de chaque Z_i est une $\mathcal{M}(1, \pi_1, \dots, \pi_K)$. Ecrire la vraisemblance complétée $L(\theta, \underline{X}, \underline{Z})$, ainsi que son logarithme.
4. Donner et démontrer les expressions des paramètres θ maximisant la vraisemblance complétée.
5. Proposer un algorithme EM pour maximiser la vraisemblance $L(\theta, \underline{X})$, en détaillant les calculs nécessaires aux différentes étapes de cet algorithme.
6. Quel critère utilisez vous pour arrêter votre algorithme ? Donner le détail de la valeur de ce critère.
7. Peut-on choisir K par maximum de vraisemblance ? Si oui, donnez l'expression analytique du maximum de vraisemblance. Si non, proposez un critère utilisable et donner son expression analytique.

2 Classification

Il s'avère que les temps d'attente $\underline{X} = (X_i)_{i=1,\dots,n}$ étudiés ci-dessus provenaient de clients de deux opérateurs téléphoniques A et B . Nous disposons donc en plus des temps X_i de la variable aléatoire $Z_i = (Z_{i1}, Z_{i2})$ avec $Z_i = (1, 0)$ si l'individu i est client de l'opérateur A , et $Z_i = (0, 1)$ si l'individu i est client de l'opérateur B . On suppose que $Z_i \sim \mathcal{M}(1, 1/2, 1/2)$.

1. Quelle est la densité de probabilité marginale de X_i ?
2. Ecrire la vraisemblance du modèle de mélange de lois exponentielles de paramètre $\theta = (\lambda_1, \lambda_2)$ pour l'échantillon $(\underline{X}, \underline{Z})$.
3. Calculer l'estimateur du maximum de vraisemblance de θ .
4. Supposons cette fois que l'on dispose d'une estimation $\hat{\theta}$ de θ . Comment classer une nouvelle observation x^* par la règle du maximum a posteriori pour ce modèle ?
5. On suppose désormais que $\hat{\theta} = (1/3, 1/4)$.
 - (a) Quelle est la probabilité d'un client de l'opérateur A attende plus de 2 minutes ? Et pour l'opérateur B ?
 - (b) Quelle est la probabilité qu'un client qui attend 2 minutes soit client de l'opérateur A ?