



Model-based learning
Examen du 04/12/2023
Durée : 2h - Tous documents autorisés

1 Classification (10 points)

Soit $\underline{X} = (X_1, \dots, X_n)$ un échantillon de n variables aléatoires p -dimensionnelles : $X_i \in \mathbb{R}^p$.

On se propose de développer un algorithme de classification (supervisée) à l'aide du modèle de mélange Gaussien suivant, pour $1 \leq k \leq K$:

$$\begin{aligned} p(Z_i = k) &= \pi \\ X_i | Z_i = k &\sim \mathcal{N}(\mu_k, \sigma^2 I_p) \end{aligned} \quad (1)$$

où I_p est la matrice identité de taille $p \times p$. Etant en classification, les données observées sont les couples $(\underline{X}, \underline{Z}) = (X_i, Z_i)_{1 \leq i \leq n}$

1. Quelle est la densité de probabilité de $X_i | Z_i = k$?
2. Quelle est la densité de probabilité marginale de X_i ?
3. Ecrire la vraisemblance du modèle de mélange (1) pour l'échantillon $(\underline{X}, \underline{Z})$.
4. Calculer l'estimateur du maximum de vraisemblance des paramètres $\theta = (\pi, \mu_k, \sigma^2)$.
5. Supposons cette fois que l'on dispose d'une estimation $\hat{\theta}$ de θ . Comment classer une nouvelle observation x^* par la règle du maximum a posteriori pour ce modèle ? Donner l'expression la plus précise possible, dans le cadre du modèle (1).

2 Clustering (10 points)

Nous désirons désormais construire un algorithme de clustering en K clusters de l'échantillon $\underline{X} = (X_i)_{i=1, \dots, n}$.

1. Ecrire la vraisemblance du modèle de mélange (1) pour l'échantillon l'échantillon $\underline{X}$.
2. Proposer un algorithme CEM pour maximiser cette vraisemblance, en détaillant précisément les calculs nécessaires aux différentes étapes de l'algorithme.
3. Pourquoi doit-on utiliser le critère BIC pour choisir le nombre de clusters et non pas la vraisemblance ? Donner l'expression précise du critère BIC dans le cadre du modèle (1).