

Données temporelles – Bloc 1 : Description

Lire une série avant de la modéliser

Jairo Cugliari

M2 MIASHS / M2 INFO – Université Lumière Lyon 2


2026–2027



Objectifs de la séance

À l'issue de cette séance, vous devrez être capables de :

- décrire correctement une série temporelle avec le vocabulaire adapté ;
- repérer tendance, saisonnalité, cycle et composante irrégulière ;
- expliquer le principe d'une décomposition en composantes non observables ;
- interpréter une autocorrélation et un corrélogramme (ACF) ;
- expliquer l'intuition de l'autocorrélation partielle (PACF) ;
- produire un **diagnostic descriptif argumenté** d'une série.



À retenir


Avant de chercher un modèle, on cherche à comprendre ce que le temps fait aux données.

1. Observer avant de définir


Activité d'ouverture : que voyez-vous ?

Observez les quatre séries. Sans vocabulaire imposé, notez ce qui vous paraît remarquable.


Série A




Série C



Série B



Série D



Question

Quels mots avez-vous utilisés ? Croissance ? répétition ? oscillation ? bruit ? régularité ? mémoire ? rupture ?

Notre objectif est de transformer ces impressions en une description :

- 1 reproductible** : deux analystes doivent pouvoir se comprendre ;
- 2 quantifiable** : les motifs visuels doivent pouvoir être mesurés ;
- 3 utile** : la description doit préparer la modélisation et la prévision.

Pourquoi les données temporelles sont-elles particulières ?

Pour des observations indépendantes, l'ordre des lignes est souvent sans importance.

Pour une série temporelle :

$$(X_1, X_2, \dots, X_T) \neq (X_{\pi(1)}, X_{\pi(2)}, \dots, X_{\pi(T)})$$

si π permute les dates.

À retenir

Permuter les observations détruit une partie de l'information : la dépendance temporelle.

2. Lexique

Une série temporelle : notation minimale

On observe une variable X à des dates ordonnées :

$$\{X_t\}_{t=1}^T = (X_1, X_2, \dots, X_T).$$

- t : indice temporel ;
- T : nombre d'observations ;
- X_t : valeur observée à la date t ;
- la date réelle peut être une seconde, un jour, un mois, un trimestre, etc.

Attention

Le temps peut être régulier (une mesure chaque heure) ou irrégulier (transactions, événements, pannes...). Dans ce cours, nous travaillerons surtout avec des séries régulièrement échantillonnées.

Fréquence, période et horizon

Fréquence / pas distance temporelle entre deux observations successives.

Période saisonnière m nombre d'observations correspondant à un cycle saisonnier.

Retard k comparaison de X_t à X_{t-k} .

Horizon h nombre de pas dans le futur que l'on souhaite prévoir.

Exemple

Données mensuelles avec saisonnalité annuelle : $m = 12$. Le retard $k = 12$ compare un mois au même mois de l'année précédente.

Mini-TD : donner du sens à un retard

Pour chaque contexte, interprétez X_{t-1} et proposez une saisonnalité plausible.

Série	X_{t-1} signifie...	Saison possible
Température horaire		
Ventes quotidiennes		
PIB trimestriel		
Consommation électrique		
30 min		
Fréquentation mensuelle		

Mini-TD : donner du sens à un retard

Pour chaque contexte, interprétez X_{t-1} et proposez une saisonnalité plausible.

Série	X_{t-1} signifie...	Saison possible
Température horaire		
Ventes quotidiennes		
PIB trimestriel		
Consommation électrique		
30 min		
Fréquentation mensuelle		

À retenir

Un retard k n'a de sens qu'en lien avec la fréquence d'observation.

Quatre mots à distinguer

Tendance

Évolution lente du niveau moyen sur le long terme.

Cycle

Oscillation de moyen/long terme sans périodicité nécessairement fixe.

Saisonnalité

Motif qui se répète avec une période connue ou identifiable.

Irrégulier / bruit

Variations restantes, non expliquées par les composantes structurées.

3. Composantes non observables

Une idée structurante : ce que l'on voit est une somme d'effets

Une représentation additive classique est :

$$X_t = T_t + S_t + C_t + R_t,$$

où :

- T_t : tendance ;
- S_t : saisonnalité ;
- C_t : cycle ;
- R_t : composante irrégulière.

À retenir

On observe X_t , jamais directement T_t , S_t , C_t ou R_t . Ces composantes sont dites **non observables**.

Additif ou multiplicatif ?

Deux représentations usuelles :

Additif : $X_t = T_t + S_t + R_t$

Multiplicatif : $X_t = T_t \times S_t \times R_t$



Additif

L'amplitude saisonnière reste approximativement constante lorsque le niveau change.

Multiplicatif

L'amplitude des variations augmente avec le niveau de la série.

Exercice : additif ou multiplicatif ?



Question

Quel schéma vous paraît le plus plausible pour chaque série ? Quelle information graphique utilisez-vous ?

Décomposer, c'est déjà modéliser

Une décomposition suppose que l'on décide :

- quelles composantes existent ;
- comment elles se combinent ;
- comment elles évoluent dans le temps ;
- ce que l'on accepte de laisser dans le résidu.

Conséquence

Une décomposition n'est pas une vérité cachée que l'algorithme "découvre". C'est une représentation utile, fondée sur des hypothèses.

4. Estimer une tendance

Comment faire apparaître une tendance ?

Idée : lisser les fluctuations rapides pour faire ressortir l'évolution lente.

Pour une moyenne mobile centrée d'ordre $2q + 1$:

$$\hat{T}_t = \frac{1}{2q + 1} \sum_{j=-q}^q X_{t+j}.$$

Intuition

Plus la fenêtre est large, plus la courbe est lisse... mais plus on risque d'effacer des variations pertinentes.

Mini-TD : moyenne mobile

On observe :

(10, 12, 11, 15, 17, 16, 20).

Calculez les trois premières moyennes mobiles centrées d'ordre 3 :

$$\hat{T}_2 = \frac{X_1 + X_2 + X_3}{3}, \quad \hat{T}_3 = \frac{X_2 + X_3 + X_4}{3}, \dots$$

Mini-TD : moyenne mobile

On observe :

(10, 12, 11, 15, 17, 16, 20).

Calculez les trois premières moyennes mobiles centrées d'ordre 3 :

$$\hat{T}_2 = \frac{X_1 + X_2 + X_3}{3}, \quad \hat{T}_3 = \frac{X_2 + X_3 + X_4}{3}, \dots$$

$$\hat{T}_2 = 11, \quad \hat{T}_3 \approx 12,67, \quad \hat{T}_4 \approx 14,33.$$

Question

Que perd-on aux extrémités? Que se passe-t-il si on augmente fortement la fenêtre?

De la série brute au résidu

Dans une logique additive :

- 1 estimer la tendance $\hat{T}_t$;
- 2 retirer la tendance : $X_t - \hat{T}_t$;
- 3 estimer la saisonnalité $\hat{S}_t$;
- 4 examiner le résidu :

$$\hat{R}_t = X_t - \hat{T}_t - \hat{S}_t.$$

À retenir

Le résidu est un objet de diagnostic : s'il reste structuré, la décomposition n'a pas tout expliqué.

Décomposition moderne : idée de STL

STL = *Seasonal and Trend decomposition using Loess*.

- estimation souple de la tendance ;
- estimation d'une composante saisonnière ;
- résidu obtenu après retrait des composantes ;
- possibilité de laisser la saisonnalité évoluer progressivement.

Dans ce bloc

Nous utilisons STL comme outil de visualisation et de diagnostic. Les choix de paramètres et variantes avancées ne sont pas l'objectif principal.

Nous savons maintenant décrire la **structure visible** d'une série.

Mais deux séries ayant une tendance et une saisonnalité similaires peuvent avoir des dynamiques très différentes.

Question suivante : les observations se “souviennent-elles” du passé ?

5. Dépendance temporelle

Retarder une série

Le retard 1 de la série est :

$$X_{t-1}.$$

On peut former des couples :




$$(X_2, X_1), (X_3, X_2), \dots, (X_T, X_{T-1}).$$

Puis tracer X_t en fonction de X_{t-1} .

Question

Si hier contient beaucoup d'information sur aujourd'hui, à quoi devrait ressembler ce nuage de points ?

Trois types de dépendance



De la covariance à l'autocovariance

Pour deux variables X et Y :

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}X)(Y - \mathbb{E}Y)].$$

Pour une série temporelle, on compare la série à elle-même décalée :

$$\gamma(k) = \text{Cov}(X_t, X_{t-k}).$$

$\gamma(k)$ est l'**autocovariance au retard k** .

Fonction d'autocorrélation (ACF)

On normalise l'autocovariance :

$$\rho(k) = \text{Corr}(X_t, X_{t-k}) = \frac{\gamma(k)}{\gamma(0)}.$$

Propriétés immédiates :

- $-1 \leq \rho(k) \leq 1$;
- $\rho(0) = 1$;
- le signe indique le sens de la dépendance linéaire ;
- la valeur absolue renseigne sur son intensité.

Estimer l'ACF à partir des données


Une estimation courante est :

$$\hat{\rho}(k) = \frac{\sum_{t=k+1}^T (X_t - \bar{X})(X_{t-k} - \bar{X})}{\sum_{t=1}^T (X_t - \bar{X})^2}.$$

Lecture


On calcule cette quantité pour $k = 1, 2, 3, \dots$ puis on représente les valeurs sous forme de **corrélogramme**.

Le corrélogramme



ACF : motif 1 – persistance

Une ACF positive qui décroît lentement indique que les observations éloignées restent corrélées.




Question

Quel type de série observé au début pourrait produire ce comportement ?

ACF : motif 2 – saisonnalité

Une saisonnalité de période m peut produire des pics aux retards $m, 2m, 3m, \dots$




À retenir

L'ACF peut révéler une périodicité qui n'est pas évidente sur un graphique court ou bruité.

ACF : motif 3 – faible mémoire

Pour une série sans dépendance temporelle marquée, les autocorrélations hors retard 0 fluctuent autour de zéro.



Bandes de confiance : comment les lire ?

Sous certaines hypothèses, une approximation souvent affichée est :

$$\pm \frac{1.96}{\sqrt{T}}.$$

- une barre qui dépasse suggère une autocorrélation difficile à attribuer au seul hasard ;
- mais on examine simultanément de nombreux retards ;
- la forme globale du corrélogramme est souvent plus informative qu'une barre isolée.

À éviter

“Une barre dépasse donc le modèle est faux” est une conclusion trop mécanique.

- 1 Une série avec tendance croissante.
- 2 Une série saisonnière de période 12.
- 3 Un bruit blanc.
- 4 Une série qui alterne souvent valeur haute / valeur basse.

Question

Pour chacune, décrivez qualitativement l'ACF attendue : signe, vitesse de décroissance, pics éventuels. Justifiez.

Attention : corrélation n'est pas causalité

Une autocorrélation forte signifie :

X_t et X_{t-k} sont linéairement associés.

Elle ne signifie pas nécessairement :

$X_{t-k} \longrightarrow X_t$ (cause).

Une tendance commune ou une saisonnalité peuvent créer une autocorrélation très forte sans mécanisme causal direct entre deux dates successives.

6. Autocorrélation partielle

Pourquoi l'ACF ne suffit-elle pas ?

Supposons que :

- X_t est fortement lié à X_{t-1} ;
- X_{t-1} est fortement lié à X_{t-2} .

Alors X_t et X_{t-2} peuvent être corrélés simplement **par l'intermédiaire de X_{t-1}** .

Question

X_{t-2} apporte-t-il encore une information propre sur X_t lorsque X_{t-1} est déjà pris en compte ?

Intuition de la PACF

L'autocorrélation partielle au retard k mesure le lien entre :

$$X_t \quad \text{et} \quad X_{t-k}$$

après avoir retiré l'effet linéaire des retards intermédiaires :

$$X_{t-1}, X_{t-2}, \dots, X_{t-k+1}.$$

À retenir

ACF = dépendance totale au retard k . PACF = dépendance "directe" restante au retard k .

Une lecture par régression

Pour comprendre la PACF au retard 2, on peut considérer :

$$X_t = \beta_0 + \beta_1 X_{t-1} + \beta_2 X_{t-2} + \varepsilon_t.$$

La question devient :

β_2 apporte-t-il encore quelque chose une fois X_{t-1} inclus ?

Cette intuition sera centrale lorsque nous étudierons les processus autorégressifs dans le bloc **Modélisation**.

ACF et PACF : ne pas apprendre des recettes trop tôt

Aujourd'hui

- décrire la dépendance ;
- repérer la mémoire ;
- identifier des périodicités ;
- distinguer dépendance totale et partielle.

Bloc Modélisation

- stationnarité ;
- processus AR et MA ;
- signatures ACF/PACF ;
- choix d'ordres p et q ;
- diagnostic des résidus.

7. Synthèse et diagnostic

Une grille de description en 6 questions

Face à une nouvelle série :

- 1 Quelle est la **fréquence** des observations ?
- 2 Le **niveau** est-il stable ou existe-t-il une tendance ?
- 3 Observe-t-on une **saisonnalité** ? Quelle période ?
- 4 L'amplitude des fluctuations est-elle stable ?
- 5 Y a-t-il des **ruptures, valeurs atypiques ou changements de régime** ?
- 6 Que montrent l'**ACF** et la **PACF** sur la dépendance temporelle ?

Tâche intégratrice : diagnostic express

Pour une série fournie avec son graphique, son ACF et sa PACF, complétez :

Diagnostic

- La série présente ...
- Je soupçonne une saisonnalité de période ... parce que ...
- L'ACF montre ...
- La PACF suggère que ...
- Avant de la modéliser, je voudrais vérifier / transformer ...

Exemple de diagnostic argumenté

Exemple

“La série mensuelle présente une tendance croissante et une saisonnalité annuelle visible. L’amplitude saisonnière augmente légèrement avec le niveau, ce qui invite à envisager une transformation ou une représentation multiplicative. L’ACF reste positive sur de nombreux retards et présente des pics autour des multiples de 12, ce qui confirme une forte persistance et une structure saisonnière. La PACF permet de distinguer les dépendances directes des effets transmis par les retards intermédiaires. Avant de proposer un processus ARMA, il faudra étudier la stationnarité.”

À retenir

Une bonne description relie le graphique, les composantes et la dépendance temporelle.

Ce que vous devez savoir faire

- Employer correctement : fréquence, période, retard, horizon, tendance, saisonnalité, cycle, résidu.
- Expliquer pourquoi l'ordre temporel contient de l'information.
- Choisir entre une lecture additive et multiplicative simple.
- Expliquer le rôle d'une moyenne mobile et d'une décomposition.
- Définir et interpréter l'ACF.
- Reconnaître persistance, saisonnalité et faible mémoire dans un corrélogramme.
- Expliquer l'idée de la PACF sans recourir à une recette de choix de modèle.

Transition vers le bloc 2 : Modélisation

Nous avons décrit **ce que fait** la série.

Le prochain bloc cherchera à répondre à trois questions :

- 1 La structure probabiliste est-elle **stable dans le temps** ?
- 2 Quel mécanisme simple peut produire les dépendances observées ?
- 3 Comment vérifier que le modèle a capturé toute l'information temporelle utile ?

Stationnarité $\longrightarrow$ AR / MA $\longrightarrow$ ARMA

Description $\rightarrow$ Modélisation $\rightarrow$
Prévision

La première étape d'une bonne prévision est une bonne lecture de la série.