

Données temporelles – Bloc 2 : Modélisation

De la dépendance observée à un mécanisme probabiliste

Jairo Cugliari

M2 MIASHS / M2 INFO – Université Lumière Lyon 2

2026–2027



Objectifs de la séance

À l'issue de cette séance, vous devrez être capables de :

- expliquer pourquoi la **stationnarité** est centrale pour modéliser une dynamique temporelle ;
- reconnaître des causes simples de non-stationnarité et proposer une transformation ;
- comprendre les mécanismes **AR**, **MA** et **ARMA** ;
- relier un mécanisme à sa signature dans l'**ACF/PACF** ;
- estimer et comparer quelques modèles candidats ;
- vérifier si les **résidus** ressemblent à un bruit blanc.

Le changement de perspective

Bloc 1 – Description

Quelles structures sont présentes dans la série ?




Bloc 2 – Modélisation

Quel mécanisme probabiliste pourrait produire ces structures ?

$$X_t = \underbrace{\text{partie prévisible}}_{\text{passé}} + \underbrace{\varepsilon_t}_{\text{information nouvelle}}$$

Le fil rouge : une chaîne de modélisation



À retenir

Un modèle n'est pas une fin : c'est une hypothèse sur la dynamique, que les résidus devront mettre à l'épreuve.

1. Pourquoi stationnariser ?

Retour au diagnostic descriptif

On sait maintenant dire :

« *La série présente une tendance, une saisonnalité et une forte dépendance temporelle.* »

Question

Peut-on apprendre une relation entre aujourd'hui et hier si cette relation elle-même change avec le temps ?

Retour au diagnostic descriptif

On sait maintenant dire :

« La série présente une tendance, une saisonnalité et une forte dépendance temporelle. »


Question

Peut-on apprendre une relation entre aujourd'hui et hier si cette relation elle-même change avec le temps ?


Idée

Pour apprendre une dynamique à partir du passé, il faut qu'elle soit suffisamment **stable dans le temps**.

Deux séries qui « bougent »... mais pas de la même façon



Série A



Série B

Question

Laquelle vous paraît compatible avec un mécanisme stable ? Sur quels indices vous appuyez-vous ?

Stationnarité faible : la définition

Un processus (X_t) est **faiblement stationnaire** si :

$$\mathbb{E}(X_t) = \mu \quad \text{pour tout } t,$$

$$\text{Var}(X_t) = \gamma(0) < \infty \quad \text{pour tout } t,$$

$$\text{Cov}(X_t, X_{t-h}) = \gamma(h),$$

c'est-à-dire que la covariance dépend du **retard** h , pas de la date t .

Question

Traduisez chacune de ces trois conditions en une phrase sans symbole mathématique.

Stationnarité stricte et faible

Stationnarité stricte

La loi jointe de $(X_{t_1}, \dots, X_{t_k})$ est inchangée lorsqu'on translate toutes les dates d'un même décalage.

Stationnarité faible

On demande seulement la stabilité des deux premiers moments et de la structure de covariance.

À retenir

Dans ce cours, la stationnarité faible sera notre cadre de travail principal.

Mini-TD : stationnaire ou non ?

Pour chaque cas, donnez votre diagnostic et **justifiez-le**.

Processus / série	Stationnaire ?	Indice principal
Bruit blanc		
Série oscillant autour d'un niveau fixe		
Série avec tendance linéaire		
Marche aléatoire $X_t = X_{t-1} + \varepsilon_t$		
Série avec saisonnalité déterministe		

2. Rendre la dynamique plus stable

Différencier : regarder les variations plutôt que les niveaux

Si le niveau évolue, on peut étudier :

$$\Delta X_t = X_t - X_{t-1}.$$


Niveau	Différence
« Combien vaut la série aujourd'hui ? »	« De combien a-t-elle changé depuis hier ? »

À retenir


La différenciation ne garantit pas la stationnarité ; elle vise à supprimer certaines évolutions systématiques du niveau.

Effet d'une différence première

Série en niveau



ΔX_t



Question

Qu'est-ce qui a disparu ? Qu'est-ce qui reste à modéliser ?

Différenciation saisonnière

Pour une saisonnalité de période s :

$$\Delta_s X_t = X_t - X_{t-s}.$$

Exemple : données mensuelles avec cycle annuel, $s = 12$.

Interprétation

On compare chaque mois au **même mois de l'année précédente** plutôt qu'au mois précédent.

Question

Quelle différence utiliseriez-vous pour des données trimestrielles avec saisonnalité annuelle ?

Autres transformations utiles

- **Logarithme** : peut stabiliser une variance qui augmente avec le niveau et convertir certains effets multiplicatifs en effets additifs.
- **Retrait d'une tendance déterministe** : modéliser puis soustraire une tendance explicite.
- **Correction saisonnière** : travailler sur une série CVS lorsque la question le justifie.

Attention

Transformer est un choix de modélisation : il faut pouvoir expliquer **ce qui a été retiré** et **dans quelle échelle** on interprétera ensuite le modèle.

3. Processus autorégressifs

AR(1) : « demain ressemble à aujourd'hui »

Le modèle autorégressif d'ordre 1 :

$$X_t = c + \phi X_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim WN(0, \sigma^2).$$

- ϕ contrôle la **mémoire** du processus ;
- ε_t est l'innovation à la date t ;
- avec $|\phi| < 1$, le processus peut être stationnaire autour d'un niveau stable.

Question

Avant de calculer quoi que ce soit : à quoi ressembleraient des trajectoires avec $\phi = 0, 0.3, 0.9, -0.8, 1$?

AR(1) : le rôle de ϕ

ϕ	Comportement attendu
0	aucune mémoire linéaire : bruit blanc
$0 < \phi \ll 1$	persistance faible, retour rapide vers le niveau moyen
$\phi \approx 1$	forte persistance, retour très lent
$-1 < \phi < 0$	alternance / oscillation autour du niveau moyen
$\phi = 1$	marche aléatoire : la stationnarité est perdue

À retenir

Un seul paramètre peut produire des trajectoires qualitativement très différentes.

AR(1) stationnaire : moyenne et autocorrélation

Pour $X_t = c + \phi X_{t-1} + \varepsilon_t$ avec $|\phi| < 1$:

$$\mathbb{E}(X_t) = \mu = \frac{c}{1 - \phi}.$$

Et l'autocorrélation vérifie :

$$\rho(h) = \phi^h.$$

Conséquence graphique

L'ACF ne s'arrête pas brutalement : elle **décroît progressivement**. Si $\phi < 0$, les signes alternent.

Du AR(1) au AR(p)

$$X_t = c + \phi_1 X_{t-1} + \dots + \phi_p X_{t-p} + \varepsilon_t.$$

Lecture

La valeur présente dépend directement des p dernières valeurs observées, auxquelles s'ajoute une innovation nouvelle.

Question

Dans un AR(2), une corrélation entre X_t et X_{t-3} implique-t-elle nécessairement un effet direct du retard 3 ?

Du AR(1) au AR(p)

$$X_t = c + \phi_1 X_{t-1} + \dots + \phi_p X_{t-p} + \varepsilon_t.$$

Lecture

La valeur présente dépend directement des p dernières valeurs observées, auxquelles s'ajoute une innovation nouvelle.

Question

Dans un AR(2), une corrélation entre X_t et X_{t-3} implique-t-elle nécessairement un effet direct du retard 3 ?

À retenir

Non : une dépendance peut être transmise indirectement par les retards intermédiaires. C'est précisément ce que la PACF aide à distinguer.

4. Processus moyenne mobile

MA(1) : la mémoire des chocs


Un processus moyenne mobile d'ordre 1 s'écrit :

$$X_t = \mu + \varepsilon_t + \theta\varepsilon_{t-1}.$$

Changement de mécanisme

X_t ne dépend pas directement de X_{t-1} . Deux observations voisines sont corrélées parce qu'elles **partagent un même choc**.

Visualiser le partage des innovations



Question

Pourquoi X_t et X_{t-2} ne partagent-ils plus aucune innovation dans un MA(1) ?

MA(q) : une mémoire finie des chocs

$$X_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}.$$

Deux observations séparées de plus de q périodes ne partagent plus d'innovation.

Signature théorique

Pour un MA(q), l'ACF est nulle au-delà du retard q : on parle de **coupure** de l'ACF.

À retenir

AR : mémoire portée par les valeurs passées. MA : mémoire portée par les chocs passés.

5. ACF/PACF et identification

Deux mécanismes, deux signatures

Processus	ACF	PACF
$AR(p)$	décroissance progressive	coupure après p
$MA(q)$	coupure après q	décroissance progressive
$ARMA(p, q)$	décroissance	décroissance


Prudence

Ce tableau décrit des **signatures théoriques**. Une ACF/PACF estimée sur un échantillon est bruitée : l'identification reste une démarche d'analyse, pas une recette automatique.

Mini-TD : trois diagnostics

Pour chaque paire ACF/PACF, proposez un mécanisme candidat.

Cas A



ACF :

décroissance
PACF : pic à 1

Cas B



ACF :

coupure à 1
PACF : décroissance

Cas C



ACF et

PACF : décroissance

ARMA : réunir les deux mécanismes

$$X_t = c + \sum_{i=1}^p \phi_i X_{t-i} + \varepsilon_t + \sum_{j=1}^q \theta_j \varepsilon_{t-j}.$$

AR

Mémoire des
valeurs passées

MA

Mémoire des
chocs passés

Innovation

Information
nouvelle

p = ordre autorégressif ;

q = ordre moyenne mobile.

Positionner ARIMA sans l'ouvrir complètement

Si une série devient stationnaire après d différenciations, puis suit un $\text{ARMA}(p, q)$, on parle d'un :

$$\boxed{\text{ARIMA}(p, d, q)}.$$

Exemple conceptuel

$\text{ARIMA}(1, 1, 0)$: on modélise les **différences** par un $\text{AR}(1)$.

À retenir

Le « I » signifie *Integrated* : la différenciation fait le pont entre non-stationnarité et modélisation ARMA.

6. Estimer un modèle

De la théorie aux données

Workflow pratique :

série $\rightarrow$ transformation $\rightarrow$ ACF/PACF $\rightarrow$ modèles candidats $\rightarrow$ estimation.

Par exemple, après inspection, on peut comparer :

$AR(1)$, $AR(2)$, $MA(1)$, $ARMA(1, 1)$.

Question

Pourquoi ne pas simplement choisir le modèle qui ajuste le mieux les données observées ?

Estimation : ce que fait le logiciel

Le logiciel choisit des valeurs de ϕ_i , θ_j , c et σ^2 compatibles avec les observations.

Maximum de vraisemblance – intuition

On recherche les paramètres sous lesquels les données effectivement observées seraient les plus plausibles.

Sorties typiques :

- coefficients estimés et incertitude ;
- log-vraisemblance ;
- AIC / BIC ;
- résidus du modèle.

AIC : ajustement contre complexité

$$AIC = -2\ell + 2k,$$

où ℓ est la log-vraisemblance maximisée et k le nombre de paramètres estimés.

Bon ajustement

augmente ℓ
et diminue l'AIC

Complexité

augmente k
et pénalise l'AIC

À retenir

On compare des modèles ajustés à la **même série** / **même transformation**. Un AIC plus faible est préféré parmi les candidats comparables.

Mini-TD : choisir sans surinterpréter

Modèle	nb. paramètres	AIC	ACF résiduelle
AR(1)	2	512.4	structure visible
AR(2)	3	498.7	presque plate
ARMA(1,1)	3	497.9	presque plate
ARMA(3,2)	6	497.4	presque plate

Question

Quel(s) modèle(s) garderiez-vous pour la suite ? Quelles informations supplémentaires voudriez-vous regarder ?

7. Diagnostiquer le modèle

Si le modèle a capturé la dynamique temporelle, que doit-il rester ?

Si le modèle a capturé la dynamique temporelle, que doit-il rester ?

Réponse

Des résidus qui ressemblent à un **bruit blanc** : centrés, sans structure temporelle exploitable, avec une variance raisonnablement stable.

Diagnostic résiduel : trois regards

- 1 **Graphique des résidus** : niveau, variance, valeurs atypiques, ruptures.
- 2 **ACF des résidus** : reste-t-il de la dépendance temporelle ?
- 3 **Test global** : plusieurs autocorrélations résiduelles sont-elles conjointement compatibles avec zéro ?

À retenir

Un bon ajustement sur les données n'est pas suffisant : le modèle doit aussi laisser des résidus sans structure.

Ljung–Box : une vérification globale

Pour un horizon m , le test de Ljung–Box examine :

$$H_0 : \rho_1 = \rho_2 = \dots = \rho_m = 0$$

contre l'idée qu'au moins une autocorrélation résiduelle subsiste.

Lecture pratique


Une petite p-valeur signale que le modèle a probablement laissé de la dépendance temporelle dans les résidus.

Mais...

La p-valeur ne remplace ni le graphique des résidus ni l'ACF. Elle complète le diagnostic.

Deux modèles, deux résidus


Modèle A



résidus

ACF des

Modèle B



résidus


ACF des

Question

Lequel a mieux capturé la dépendance ? Que feriez-vous avec l'autre ?

8. Synthèse

La chaîne complète



À chaque étape, une question

Stable? Quel mécanisme? Quels paramètres? Que reste-t-il dans les résidus?

Tâche de synthèse : votre diagnostic en 5 phrases

On vous donne une série, son ACF/PACF, deux modèles estimés et leurs résidus.

- 1 La série semble-t-elle stationnaire ? Pourquoi ?
- 2 Quelle transformation proposeriez-vous si nécessaire ?
- 3 Quel mécanisme AR/MA/ARMA est plausible ?
- 4 Quel modèle retenez-vous après estimation ?
- 5 Les résidus permettent-ils de valider provisoirement ce choix ?

À retenir

Une modélisation convaincante est une **argumentation statistique**, pas seulement un appel de fonction.

Nous avons maintenant un modèle qui explique raisonnablement la dynamique passée.

**Comment utiliser cette dynamique pour construire une
prévision ?** Prochaines questions :

- prévision ponctuelle et intervalle de prévision ;
- horizon et propagation de l'incertitude ;
- validation temporelle et métriques ;
- comparaison ARMA / méthodes de machine learning.