

Données temporelles – Bloc 3 : Prévision

Du prédicteur statistique aux modèles non linéaires de machine learning

Jairo Cugliari

M2 MIASHS / M2 INFO – Université Lumière Lyon 2

2026–2027




Objectifs de la séance

À l'issue de cette séance, vous devrez être capables de :

- définir une **prévision statistique** à partir de l'information disponible ;
- distinguer prévision ponctuelle, erreur et incertitude prédictive ;
- construire et interpréter une prévision ARMA à plusieurs horizons ;
- évaluer une méthode **hors échantillon** avec une métrique adaptée ;
- transformer une série temporelle en problème d'**apprentissage supervisé** ;
- utiliser des prédicteurs non linéaires et éviter les **fuites d'information** ;
- comparer équitablement une approche ARMA et une approche machine learning.

Le fil rouge des trois blocs



Information disponible à t $\longrightarrow$ prédiction de X_{t+h}

1. Qu'est-ce que prévoir ?

Situation-problème

À la date t , on a observé :

$$X_1, X_2, \dots, X_t.$$

Demain, X_{t+1} sera observé, mais aujourd'hui il est inconnu.

Question

Quelle valeur annonceriez-vous pour X_{t+1} ? Et surtout : qu'est-ce qui ferait qu'une réponse est meilleure qu'une autre ?

Situation-problème

À la date t , on a observé :

$$X_1, X_2, \dots, X_t.$$

Demain, X_{t+1} sera observé, mais aujourd'hui il est inconnu.

Question

Quelle valeur annonceriez-vous pour X_{t+1} ? Et surtout : qu'est-ce qui ferait qu'une réponse est meilleure qu'une autre ?

Trois objets différents

- la **valeur future** X_{t+h} : inconnue à la date t ;
- la **prévision** $\hat{X}_{t+h|t}$: calculée avec l'information disponible ;
- l'**erreur** $e_t(h) = X_{t+h} - \hat{X}_{t+h|t}$: connue seulement plus tard.

L'information disponible

On note

$\mathcal{F}_t$ = information disponible au temps t .

Dans le cas le plus simple :

$$\mathcal{F}_t = \{X_t, X_{t-1}, X_{t-2}, \dots\}.$$

Mais $\mathcal{F}_t$ peut aussi contenir :

- température connue ou prévue ;
- calendrier, jour de semaine, vacances ;
- variables économiques ;
- informations métier disponibles au moment de prévoir.

À retenir

Une prévision ne doit utiliser que de l'information réellement disponible au moment où elle est produite.

« Meilleure » prévision : il faut choisir une perte

Une prévision $\hat{y}$ est évaluée par une fonction de perte $L(y, \hat{y})$.

Perte quadratique

$$L(y, \hat{y}) = (y - \hat{y})^2$$

Le prédicteur optimal est

$$\boxed{\hat{X}_{t+h|t} = \mathbb{E}(X_{t+h} \mid \mathcal{F}_t)}.$$

Perte absolue

$$L(y, \hat{y}) = |y - \hat{y}|$$

Le prédicteur optimal est une **médiane conditionnelle**.

Question

Peut-on parler de « meilleure prévision » sans préciser ce que coûte une erreur ?

Pourquoi l'espérance conditionnelle ?

Pour toute prévision a mesurable par rapport à $\mathcal{F}_t$:

$$\mathbb{E}[(X_{t+h} - a)^2 \mid \mathcal{F}_t]$$

se décompose en

$$\underbrace{\text{Var}(X_{t+h} \mid \mathcal{F}_t)}_{\text{incertitude irréductible}} + \underbrace{(\mathbb{E}[X_{t+h} \mid \mathcal{F}_t] - a)^2}_{\text{erreur due au choix de } a}.$$

Le second terme est minimal pour

$$a = \mathbb{E}[X_{t+h} \mid \mathcal{F}_t].$$

À retenir

Sous perte quadratique, prévoir revient à approximer une espérance conditionnelle. Cette idée restera valable quand nous passerons au machine learning.

2. ARMA comme premier prédicteur


AR(1) : prévoir à un pas

Reprenons un modèle connu :

$$X_{t+1} = \phi X_t + \varepsilon_{t+1}, \quad \mathbb{E}(\varepsilon_{t+1} \mid \mathcal{F}_t) = 0.$$

Donc :

$$\hat{X}_{t+1|t} = \mathbb{E}(X_{t+1} \mid \mathcal{F}_t) = \boxed{\phi X_t}.$$



AR(1) : prévoir plusieurs pas

À deux pas :

$$X_{t+2} = \phi X_{t+1} + \varepsilon_{t+2} = \phi^2 X_t + \phi \varepsilon_{t+1} + \varepsilon_{t+2}.$$

À la date t , les innovations futures ont une espérance nulle :

$$\widehat{X}_{t+2|t} = \phi^2 X_t.$$

Par récurrence :

$$\widehat{X}_{t+h|t} = \phi^h X_t.$$

Interprétation

Si $|\phi| < 1$, l'effet de l'observation présente s'atténue avec l'horizon.

Mini-TD : avant de calculer

Supposons $X_t = 10$.

Modèle	ϕ	Que prévoyez-vous qualitativement ?
A	0.2	?
B	0.9	?
C	-0.8	?

Pour chaque modèle :

- 1 calculer $\hat{X}_{t+1|t}$ et $\hat{X}_{t+5|t}$;
- 2 commenter persistance et éventuelles oscillations ;
- 3 anticiper la limite quand $h \rightarrow \infty$.

Prévision ponctuelle $\neq$ certitude

Pour AR(1),

$$X_{t+h} = \phi^h X_t + \sum_{j=0}^{h-1} \phi^j \varepsilon_{t+h-j}.$$

La prévision est

$$\phi^h X_t,$$


mais les innovations futures restent inconnues. L'erreur de prévision vaut :

$$e_t(h) = \sum_{j=0}^{h-1} \phi^j \varepsilon_{t+h-j},$$

d'où

$$\text{Var}[e_t(h)] = \sigma^2 \sum_{j=0}^{h-1} \phi^{2j}.$$

L'incertitude augmente avec l'horizon



ARMA : même principe, calcul récursif

Pour un ARMA(p, q) :

$$X_t = c + \sum_{i=1}^p \phi_i X_{t-i} + \varepsilon_t + \sum_{j=1}^q \theta_j \varepsilon_{t-j}.$$

Pour prévoir :

- les X_s passés sont connus ;
- les innovations passées sont remplacées par les résidus estimés ;
- les innovations futures sont remplacées par leur espérance : 0 ;
- les futures valeurs inconnues de X sont remplacées récursivement par leurs prévisions.

À retenir

Le logiciel automatise le calcul ; le principe reste une espérance conditionnelle à l'information disponible.

3. Évaluer avant de complexifier

Une prévision doit être jugée sur le futur

On découpe chronologiquement :

$$\underbrace{X_1, \dots, X_T}_{\text{apprentissage}} \quad \underbrace{X_{T+1}, \dots, X_{T+H}}_{\text{test}}$$

Le modèle est estimé uniquement sur la partie **apprentissage**.

Principe

La performance qui nous intéresse est la performance sur des observations qui n'ont pas servi à ajuster le modèle.

Mesurer l'erreur

Pour des erreurs $e_i = y_i - \hat{y}_i$:

$$MAE = \frac{1}{n} \sum_{i=1}^n |e_i|, \quad RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n e_i^2}.$$

MAE

Interprétation directe dans l'unité de Y .
Moins sensible aux très grosses erreurs.

RMSE

Pénalise davantage les grosses erreurs.
Cohérent avec une perte quadratique.

Question

Une méthode A avec MAE plus faible mais RMSE plus élevé est-elle nécessairement meilleure ?

Toujours comparer à un modèle simple

Avant ARMA, forêt ou boosting, construire un **benchmark**.

- Naïf :

$$\hat{X}_{t+1|t} = X_t.$$

- Naïf saisonnier :

$$\hat{X}_{t+h|t} = X_{t+h-s}.$$

- Moyenne historique, lorsque cela a un sens.

Règle pratique

Un modèle sophistiqué qui ne bat pas une prévision naïve n'apporte pas de valeur prédictive.

Le piège du découpage aléatoire

En apprentissage supervisé classique, on mélange souvent les lignes avant de créer train/test.




mélange temporel

Pour une série temporelle, cela peut faire apprendre au modèle des informations provenant du « futur » relativement aux observations de test.

Le temps impose l'ordre de validation.

Pause : où en sommes-nous ?



Question

Et si la relation entre le passé et le futur n'était pas linéaire ?

4. Du temporel à l'apprentissage supervisé

Changer de représentation

Une série :

$$X_1, X_2, \dots, X_T$$

peut être transformée en tableau :

X_{t-1}	X_{t-2}	X_{t-3}	cible
X_3	X_2	X_1	X_4
X_4	X_3	X_2	X_5
X_5	X_4	X_3	X_6
$\vdots$	$\vdots$	$\vdots$	$\vdots$

Ainsi :

$$(X_{t-1}, X_{t-2}, X_{t-3}) \longmapsto X_t.$$

À retenir

Nous venons de transformer la prévision temporelle en problème de régression supervisée.

Un AR est déjà une régression sur des retards

Un $AR(p)$ écrit :

$$X_t = \beta_0 + \beta_1 X_{t-1} + \cdots + \beta_p X_{t-p} + \varepsilon_t.$$

En langage machine learning :

$$\underbrace{(X_{t-1}, \dots, X_{t-p})}_{\text{features}} \xrightarrow{f} \underbrace{X_t}_{\text{target}},$$

avec

$$f(x_1, \dots, x_p) = \beta_0 + \sum_{j=1}^p \beta_j x_j.$$

Question

Que change le machine learning ?

Un AR est déjà une régression sur des retards

Un $AR(p)$ écrit :

$$X_t = \beta_0 + \beta_1 X_{t-1} + \cdots + \beta_p X_{t-p} + \varepsilon_t.$$

En langage machine learning :

$$\underbrace{(X_{t-1}, \dots, X_{t-p})}_{\text{features}} \xrightarrow{f} \underbrace{X_t}_{\text{target}},$$

avec

$$f(x_1, \dots, x_p) = \beta_0 + \sum_{j=1}^p \beta_j x_j.$$

Question

Que change le machine learning ?

Il permet principalement de chercher f dans une classe de fonctions beaucoup plus flexible.

Et si la relation était non linéaire ?


Supposons :

$$X_t = 0.6X_{t-1} + 0.3X_{t-1}^2 + \varepsilon_t.$$

Un AR(1) cherche une droite :

$$f(x) = \beta_0 + \beta_1 x.$$

Mais la vraie relation est courbe.



Bleu : relation non linéaire. Orange : approximation linéaire.

Le cadre commun

On peut écrire les deux approches sous la même forme :

$$X_t = f(\text{information passée}) + \varepsilon_t$$

Modélisation classique

f est structurée et paramétrique :

$$f(x) = \beta_0 + \sum_j \beta_j x_j.$$

Machine learning

f est plus flexible :

f = arbre, forêt, boosting, réseau, ...

À retenir


Le ML ne change pas le problème de prévision ; il élargit la classe de prédicteurs que l'on peut apprendre.

5. Deux prédicteurs non linéaires

Arbre de régression : des règles plutôt qu'une droite

Un arbre peut apprendre des règles comme :

$$\hat{X}_t = \begin{cases} a, & X_{t-1} < c_1, \\ b, & X_{t-1} \geq c_1 \text{ et } X_{t-7} < c_2, \\ d, & \text{sinon.} \end{cases}$$



Un arbre capture naturellement seuils et interactions, mais peut être instable et surajuster.

Random Forest : moyenner beaucoup d'arbres

Une forêt construit plusieurs arbres sur des versions perturbées des données et des variables, puis moyenne :

$$\hat{f}(x) = \frac{1}{B} \sum_{b=1}^B \hat{f}_b(x).$$

Intuition

Chaque arbre est instable ; leur moyenne réduit la variance et donne un prédicteur plus robuste.


- non-linéarités : oui ;
- interactions : oui ;
- mise à l'échelle : généralement inutile ;
- extrapolation hors de la plage observée : limitée.

Gradient Boosting : corriger progressivement les erreurs

Le boosting construit :

$$\hat{f}_M(x) = \hat{f}_0(x) + \eta \sum_{m=1}^M g_m(x),$$

où chaque nouvel arbre g_m cherche à corriger les erreurs du modèle précédent.



Attention

Plus flexible ne signifie pas automatiquement plus performant : profondeur, nombre d'arbres et taux d'apprentissage doivent être validés hors échantillon.

Pourquoi ne pas commencer par un LSTM ?

Les réseaux récurrents et architectures profondes sont possibles, mais ils introduisent simultanément :

- davantage de paramètres ;
- davantage de choix d'architecture ;
- davantage de données nécessaires ;
- une optimisation plus délicate ;
- une interprétation plus difficile.

Choix pédagogique

Pour comprendre le passage **linéaire** → **non linéaire**, Random Forest et Gradient Boosting suffisent et conservent une représentation tabulaire transparente.

6. Feature engineering temporel

Les retards ne sont qu'un début

Pour prévoir X_t , on peut construire :

$$X_{t-1}, X_{t-2}, X_{t-7}, X_{t-12},$$

mais aussi :

$$\overline{X}_{t-1:t-7}, \quad s_{t-1:t-30}, \quad \text{jour de semaine}, \quad \text{mois}.$$

Et éventuellement des variables externes :

température, prix, promotion, vacances, ...

À retenir

Le choix des variables explicatives devient une partie centrale de la modélisation.

Mini-TD : repérer la fuite d'information

On veut prévoir les ventes du jour t à 8 h. Quelles variables sont admissibles ?

- 1 ventes de $t - 1$;
- 2 moyenne des ventes de $t - 7$ à $t - 1$;
- 3 moyenne des ventes de $t - 3$ à $t + 3$;
- 4 jour de semaine ;
- 5 température réellement observée à 16 h le jour t ;
- 6 prévision météo disponible à 8 h ;
- 7 ventes totales du jour t .

Question

Pour chaque variable : était-elle connue à 8 h ?

La fuite peut être très discrète

Supposons une moyenne mobile :

$$M_t = \frac{X_{t-2} + X_{t-1} + X_t + X_{t+1} + X_{t+2}}{5}.$$

Utiliser M_t pour prévoir X_t paraît raisonnable graphiquement...

La fuite peut être très discrète

Supposons une moyenne mobile :

$$M_t = \frac{X_{t-2} + X_{t-1} + X_t + X_{t+1} + X_{t+2}}{5}.$$

Utiliser M_t pour prévoir X_t paraît raisonnable graphiquement...

Mais

M_t contient X_t lui-même et même X_{t+1}, X_{t+2} : le futur a contaminé les variables d'entrée.

Une feature temporelle doit être construite en respectant exactement la date à laquelle la prévision aurait été produite.

7. Validation temporelle

Validation walk-forward / rolling origin

Au lieu d'un seul découpage, on répète l'expérience :



Chaque validation simule une vraie prévision : on apprend sur le passé, on évalue sur une période future.

Avantage

On mesure la stabilité de la performance à plusieurs dates, pas seulement sur une coupure arbitraire.

Hyperparamètres : ne pas utiliser le test pour choisir

Pour un Random Forest :

profondeur, nombre d'arbres, nombre de variables testées, ...

Pour le boosting :

profondeur, η , M , ...

Ces choix doivent être faits sur des fenêtres de **validation temporelle**.

Train $\rightarrow$ Validation $\rightarrow$ Test final

Le test final ne doit servir qu'à l'évaluation finale.

Prévoir plusieurs horizons avec le ML

Pour $h > 1$, deux stratégies courantes :

Réursive

Apprendre

$$X_{t+1} = f(\text{passé})$$

puis réutiliser les prévisions comme entrées.

Directe

Apprendre un modèle par horizon :


$$X_{t+h} = f_h(\text{passé}).$$

- réursive : simple, mais les erreurs peuvent s'accumuler ;
- directe : plus de modèles, mais pas de propagation réursive identique.

8. ARMA contre ML ?

Une confrontation équitable

Pour comparer deux méthodes :



Question

Que vaut une comparaison où ARMA prévoit à un pas et le modèle ML est évalué à sept pas ?

ARMA et ML : forces différentes

	ARMA	ML tabulaire
Relation	essentiellement linéaire	potentiellement non linéaire
Structure	probabiliste explicite	fonction prédictive flexible
Variables externes	possibles, avec extension	naturelles
Interprétation	souvent forte	variable
Incertitude	intégrée au modèle	nécessite une méthode dédiée
Données	efficace sur petits/moyens échantillons	flexibilité utile avec davantage de données
Surapprentissage	contrôlé par structure	vigilance accrue
Extrapolation	structurée par le modèle	souvent difficile pour les arbres

Plus complexe n'est pas forcément meilleur

Imaginez les résultats sur le même jeu de test :

Méthode	<i>MAE</i>	<i>RMSE</i>
<i>Naïf</i>	12.1	16.8
<i>ARMA</i>	9.4	13.0
<i>RandomForest</i>	9.7	13.4
<i>GradientBoosting</i>	9.2	12.9

Question

Quel modèle choisiriez-vous ?

Plus complexe n'est pas forcément meilleur

Imaginez les résultats sur le même jeu de test :

Méthode	<i>MAE</i>	<i>RMSE</i>
<i>Naïf</i>	12.1	16.8
<i>ARMA</i>	9.4	13.0
<i>RandomForest</i>	9.7	13.4
<i>GradientBoosting</i>	9.2	12.9

Question

Quel modèle choisiriez-vous ?

La réponse ne dépend pas seulement d'un classement :

- différence de performance substantielle ou minime ?
- stabilité dans le temps ?
- besoin d'interprétation ?
- besoin d'intervalles de prévision ?
- coût de maintenance ?

Le cas où le ML doit gagner

Supposons que la dynamique dépende de :

X_{t-1} , X_{t-7} , température, jour de semaine,

avec un effet du type :

si température $> 30^\circ$ et week-end, alors forte hausse.

Cette interaction à seuil est naturelle pour un arbre ou un boosting.

Mais

Il faut encore démontrer que cette flexibilité améliore réellement les prévisions **hors échantillon**.

Le cas où ARMA peut gagner

Si la série est :

- relativement courte ;
- stationnaire après une transformation simple ;
- dominée par une dépendance linéaire régulière ;
- sans beaucoup de variables externes utiles ;

un ARMA parcimonieux peut être difficile à battre.

À retenir

Le ML n'est pas « après » ARMA dans une hiérarchie de sophistication. Ce sont des classes de prédicteurs à confronter au même problème.

9. Synthèse

Une seule question, plusieurs classes de fonctions

Le problème général est :

$$\hat{X}_{t+h|t} = f(\mathcal{F}_t)$$

ARMA


f est issue d'un modèle probabiliste paramétrique, structuré et principalement linéaire.

Machine learning

f est apprise dans une famille flexible, capable de non-linéarités et d'interactions.

Dans les deux cas, le juge final est la performance future sur une évaluation temporelle honnête.

La chaîne de prévision à retenir



Prévoir $\neq$ ajuster le passé.

Question finale

Un Gradient Boosting obtient un RMSE inférieur de 3 % à celui d'un ARMA sur le jeu de test.

Lequel choisissez-vous ?

Question finale

Un Gradient Boosting obtient un RMSE inférieur de 3 % à celui d'un ARMA sur le jeu de test.

Lequel choisissez-vous ?


Il manque encore des informations :

- la différence est-elle stable dans le temps ?
- quel est le coût des grosses erreurs ?
- faut-il expliquer les prédictions ?
- faut-il produire une distribution prédictive ?
- les variables nécessaires seront-elles disponibles en production ?

À retenir

Une bonne prévision est une décision statistique évaluée dans les conditions réelles d'utilisation.

Les trois blocs du cours



Observer → Formaliser → Prévoir